



1. Summary

- ◆ 목표: 주행 중 SoC, 온도, SoP, 주행 가능 거리, 임계 온도 도달 시간 동시 예측
- ◆ 접근: 시계열 AI(LSTM-TCN-Transformer) 비교 → 최적 모델 채택
- ◆ 운영: AWS IoT-EC2-WebSocket 실시간 대시보드
- ◆ 효과: 사전 위험 감지, 전력-페이스 전략 최적화, 안전성 강화

2. Conceptual design

I. 문제점 및 현재 상황

Formula 경주에서는 배터리 상태를 실시간으로 예측해 선제 대응하는 능력이 안정성과 성능 최적화의 핵심이다. 하지만 현 시스템은 센서 값 단순 모니터링에 머물러 미래 상태 예측이 부족해, 주행 중 과열·출력 저하·주행 가능 거리 오산 같은 문제가 발생한다. 경기 특성상 의사결정 시간이 짧으므로, 예측 기반 배터리 관리가 필수 요건이다.

II. 개발 목적


본 시스템의 개발 목적은 배터리 셀 온도, SoC, 주행 가능 거리, 가용 출력(SoP), 임계 온도 도달 시간을 실시간으로 예측해 주행 전략을 최적화하고 안전성을 높이는 것이다. 이를 통해 운영 팀과 운전자가 주행 중 상태 변화를 사전에 파악하고 상황에 맞는 의사결정을 신속히 내리도록 지원한다. 또한 예측 모델을 클라우드 기반으로 배포해 다양한 차량과 환경으로의 확장·적용을 용이하게 한다.

3. Preliminary design


I. 시스템 구성 개요



II. 배터리 실험 및 데이터 수집




III. 데이터 선정 이유 및 Input, Output 정의




본 프로젝트 데이터는 실제 Formula 차량과 동일한 배터리 셀, 부하 조건, 측정 주기를 적용하여 모델의 실주행 적용 신뢰도를 확보했다. 또한, 온도, 전류 등 기본 변수 외에 에너지 소비량, 온도 변화율과 같은 파생 변수를 추가 구성하여, 배터리의 복잡한 상태 변화를 정밀하게 학습하고 예측 정확도를 극대화하도록 설계하였다.

IV. 데이터 전처리 및 피처 생성



4. Detail design

I. 모델 구조 설계



LSTM 모델 : 입력 시퀀스를 따라 은닉 상태(h)와 셀 상태(c)를 갱신한다. 입력·망각·출력 게이트가 정보를 선택적 통과시켜 장기 의존성을 보존하며 기술기 소실과 폭주를 완화한다. 기본 RNN의 단순 순환을 게이트와 셀 메모리로 개선해 안정적으로 학습하고, 다중·양방향·드롭아웃으로 표현력을 높인다.

II. 학습설정

핵심 학습 파라미터

- ▶ Epochs 50
- ▶ 최적화 함수 Adam
- ▶ 손실 함수 Smooth L1 기반

데이터 시퀀스 구성

- ▶ 샘플링 간격 0.25초 (4Hz)
- ▶ 입력 시퀀스 60초 (120steps)
- ▶ 예측 시퀀스 60초 (120steps)

학습 성능 및 안정성 확보

- ▶ 학습 안정화 Gradient Clipping
- ▶ 학습 속도 향상 AMP
- ▶ 최적 모델 저장 Checkpoint


III. 하이퍼파라미터 탐색

Optuna의 TPE sampler 방식을 통해 최적 하이퍼파라미터를 설정

LSTM		TCN		Transformer	
HyperParam	Values	HyperParam	Values	HyperParam	Values
batch_size	512	batch_size	64	batch_size	512
learning_rate	4.72e-6	learning_rate	5.82e-6	learning_rate	5.42e-2
hidden_size	256	kernel_size	6	d_model	64
num_layers	1	num_channels	[128, 256, 256]	dim_feedforward	128
dropout	0.25	dropout	0.05	nhead	8
				encoder_layers	3
				dropout	0.05
MAE	0.3285	MAE	0.3369	MAE	0.2331

IV. 모델 학습/모델 학습 결과/모델 비교 및 선정


val loss curve



QCD (Quality, Cost, Delivery) 평가

MODEL	Train_time(s)	latency(ms)	GPU_peak_mem (Mb)	CPU_peak_mem (Mb)	Total MAE
LSTM	0.1426	0.0500	25.84375	1253.711	0.5709
TCN	0.1974	0.0595	6.67334	1272.48	0.4004
Transformer	0.2794	0.0555	59.450	1254.328	0.3537

모델별 Scattering & Error_Histogram



Quality는 MAE로 Cost는 Train time과 GPU, CPU peak memory로 Delivery는 Latency로 각각 평가 하였다. 위 QCD 평가표와 같이 각 모델을 평가하였을 때 Transformer 모델이 가장 우수하다. Transformer 모델은 Cost와 Delivery 측면에서는 일부 열세를 보이나 본 프로젝트의 핵심 목표인 정확한 예측(Quality)에서 우위를 보인다. 특히 P_avail 오차(±1.645W)는 유일하게 센서 측정 오차(±3.795W)보다 높은 정확도를 보인다. Delivery측면의 열세의 경우 실제 적용 환경 (Nvidia A10G)의 우수한 성능을 고려할 때 충분히 해결 가능한 문제이므로, 품질 측면의 명확한 장점을 바탕으로 Transformer를 채택하였다.

5. Manufacturing

1. 실험 데이터 확보

실제 차량 배터리 팩을 모사한 실험 환경을 구축해 배터리 사이클러를 이용해 다양한 충·방전 시나리오를 수행하며, 학습에 필요한 시계열 데이터를 확보.

2. 예측 모델 개발

데이터 전처리 후 LSTM, TCN, Transformer 모델을 활용해 배터리의 핵심 상태(SoC, 온도, 가용 출력 등)를 예측하도록 학습. MAE와 R² 스코어로 성능을 평가하고, TPE 기법으로 하이퍼파라미터를 탐색 모델 최적화

3. 실시간 시스템 구현 및 검증

클라우드(AWS) 기반의 자동차 파이프라인을 구축. 차량 데이터는 IoT Core를 통해 수집되어 EC2에서 예측하며, 결과는 WebSocket을 통해 시각화·주행 데이터를 반영해 모델을 지속적으로 Fine-tuning하여 계절, 노후화 등 환경에 대한 적응력을 높임.

6. Conclusion

본 기술아이디어는 GRPA580140 파우치형 셀을 대상으로 충방전-HPPC 실험을 수행해 실주행과 유사한 데이터셋을 구축하고, 이를 LSTM-TCN-Transformer 모델 학습에 활용한 뒤 차량의 CAN 시계열 데이터와 연동하여 SoC, SoP, 온도, 주행 가능 거리를 차량 내에서 직접 예측·활용하도록 설계했다. 예측 모델은 텔레메트리로 서버에 수집되는 스트림 데이터를 실시간 처리해 가중치를 주기적으로 갱신하며, 트랙 조건·계절·주행 환경·운전 패턴이 바뀌어도 성능을 유지하도록 지속 적응 구조를 갖춘다. 향후 동일 셀을 2~3년 운용하며 누적될 대규모 주행 데이터를 지속적으로 재학습에 반영해 배터리 열화로 인한 성능 저하, 온도 의존성, 주행 패턴 변화를 점진적으로 학습시킨다. 이를 통해 예측 정확도와 실용성이 높아질 뿐 아니라, 데이터 기반으로 배터리 교체 주기를 정립해 자금 집행과 팀 운영의 효율을 함께 개선한다.

본 모델은 다음과 같은 방향으로 확장이 가능하다.

- (1) 예측된 SoP 온도를 기반으로 냉각 제어와 출력 제한을 실시간 최적화
- (2) 장기 주행 데이터에서 열화 인자를 추출해 예측기에 통합
- (3) 트랙·날씨·계절 등 상황별 가중치를 적용하는 방향으로 확장

최종 목표는 단순 상태 추정보다 한 단계 나아가, 데이터가 쌓일수록 성능이 상승하는 **실시간 학습형 AI 배터리 관리 플랫폼**을 완성해 주행 안정성, 성능 최적화, 전략 의사결정의 신뢰도를 동시에 끌어올리는 것이다.

7. References

- 이정영. (2023). TCN 딥러닝 모델을 이용한 최단전력 예측에 관한 연구. 정보처리학회논문지(KTSD), 12(6), 251-258. <https://kiss.kstudy.com/Detail/Ar?key=4027949>
- 이재용, 김현준, & 임정원. (2024). 다중 시계열을 이용한 장기 예측 Transformer 모델. 응용통계연구, 37(5), 583-598. <https://www.dbpia.co.kr/pdf/pdView.do?nodeId=NODE1951626>
- Khesiba, S., Blaich, A. G., Abdallah, A. B., Manzanera, A., Khalifa, K. B., & Bedoui, M. H. (2024, October). A novel hybrid grid search and tree Parzen estimator for deep learning hyperparameters optimization. In 2024 IEEE/ACIS 21st International Conference on Computer Systems and Applications (AICCSA) (pp. 1-8). IEEE. <https://lib.hanyang.ac.kr/search/i-discovery/edsee:edsee.10912622>
- 관상욱, 한동호, 박성윤, & 김종훈. (2019). LSTM 모델 기반 리튬이온 배터리 SOH 예측 알고리즘 구현. 전기학회논문지, 68(10), 1214-1221.
- Watanabe, S. (2023). Tree-Structured Parzen Estimator: Understanding Its Algorithm Components and Their Roles for Better Empirical Performance. arXiv. <https://doi.org/10.48550/arXiv.2304.11127>
- OptimumG. (n.d.). OptimumLap [Computer software]. OptimumG. <https://www.optimumg.com/optimumlap/>
- Hossain, M., Saha, S., Haque, M. E., Arif, M. T., & Oo, A. M. T. (2019). A parameter extraction method for the Thevenin equivalent circuit model of Li-ion batteries. 2019 International Conference on Advances in Computing, Communication and Control (IACC), 908-914. IEEE. <https://doi.org/10.1109/IACC.2019.00008>